

超越视觉合理性：
3DGS 机器人数字孪生中的任务后果感知动作验证

Anonymous CVPR 2026 submission

Paper ID ****

Abstract

3D Gaussian Splatting (3DGS) 正在成为具身智能的重要视觉底座，支持照片级机器人数字孪生、演示生成和动作条件场景预测。此类系统能够提供视觉真实且空间一致的机器人场景与演示，而可靠执行还要求候选动作在物理交互后实现预期任务后果。本文研究 3DGS 机器人数字孪生中的候选动作任务后果验证：给定重建场景、任务目标和候选动作，验证器估计该动作在物理交互后是否满足任务谓词。作为动机性诊断，我们构造“相同视觉、不同物理”设置，固定渲染观测、物体位姿、相机、机器人轨迹和运动学标签，仅改变摩擦、质量、质心和接触几何等隐藏物理属性。相同视觉标签下的物理后果出现分化，揭示了视觉/运动学合理性与物理任务后果一致性之间的缺口。这一现象动机化了面向 3DGS 机器人演示和机器人数字孪生的物理感知动作后果验证层。

1. Introduction

3D Gaussian Splatting (3DGS) 为具身智能提供了高保真、可重建、可渲染的三维场景表示。它能够从真实图像中恢复照片级外观，并以较高效率生成新视角渲染 [10]。这一能力使机器人系统可以从真实环境构建机器人数字孪生，并在有限实机数据之外获得更多视角、光照、物体和环境变化。

近期 3DGS 已进入机器人仿真、演示生成和未

来预测等多个环节。RoboSplat 利用 3DGS 从单条专家演示生成视觉真实的机器人演示 [27]；GSWorld 将 3DGS 渲染与 ManiSkill、SAPIEN 和 PhysX 结合，形成照片级闭环机器人仿真环境 [8, 23, 20, 21]；RoboGSim、SplatSim 和 Re³Sim 等系统进一步推动真到仿、仿到真和高保真操作数据生成 [11, 22, 5]；ManiGaussian、GWM 和 DreMa 将 Gaussian 表示用于动态场景建模和动作条件未来预测 [14, 13, 2]。这些工作表明，3DGS 已从静态视觉表示扩展为机器人数据、仿真和世界模型中的视觉底座。

机器人执行还需要在候选动作之间作出选择。一个视觉真实的场景或运动学上合理的演示，无法单独回答执行时最关键的问题：哪个候选动作能够产生预期任务后果。抓取动作可能在图像上对准目标物体，却因接触点、夹爪宽度、摩擦或质心变化而滑落；推动动作可能朝向目标区域，却因接触点偏移产生不足位移；放置动作可能在运动学上可达，却受碰撞代理或几何闭合误差影响而失败。

本文区分三个层级的合理性。视觉合理性刻画观察、渲染或预测结果的外观可信度。运动学合理性刻画轨迹、姿态或物体位姿序列的几何可行性。任务后果一致性进一步要求动作执行后的物理状态满足任务目标，例如稳定抓取、移动目标物体、完成放置、触发状态变化或满足最终状态关系。本文研究第三个层级，即候选动作在物理交互后的任务后果。

候选动作任务后果验证位于生成/预测之后、执行之前。给定一个 3DGS 场景或其派生的观测与几

何表示、一个任务目标,以及候选动作集合,该验证层输出动作成功概率、排序分数、过滤决策或置信度。候选动作可以来自策略、规划器、视觉语言模型、演示增强模块、Gaussian 世界模型或交互式动作提案;验证层关注这些候选在执行后是否满足任务谓词。

该问题在 3DGS 机器人系统中尤为突出。光度重建主要优化多视角图像解释,高斯密度与可接触表面、闭合几何和碰撞代理之间存在表示差异。隐藏物理属性在 3DGS 表示中通常具有不确定性,包括摩擦、质量、质心、接触几何、控制误差和接触响应。视觉一致的场景可以对应不同物理世界;机器人操作中的接触过程会放大这些差异,使视觉和运动学标签难以覆盖最终任务后果。

动机性诊断已经揭示这种差异。在 RoboSplat 式演示中,渲染观测和运动学标签可以保持不变,而物理重放会随物体位姿误差或隐藏物理属性变化而成功或失败。该现象说明,视觉/运动学成功标签为生成轨迹提供了重要描述,但任务后果验证需要进一步建模物理交互、隐藏属性和任务谓词。

这些观察动机化了面向 3DGS 机器人演示和机器人数字孪生的物理感知动作后果验证层。该层与重建、演示生成和动作条件预测互补,通过在执行前估计候选动作是否满足任务谓词,为动作选择和安全过滤提供依据。

2. Related Work

2.1. 视觉场景表示

神经场景表示改变了机器人系统获取真实世界外观的方式。NeRF 将多视角图像编码为连续辐射场,使新视角合成成为可学习的三维表示问题 [16]; 3D Gaussian Splatting 则以显式高斯图元和高效光栅化将高质量渲染推进到实时交互尺度 [10]。这一效率差异对机器人尤其关键:相机视角会随手眼运动频繁变化,训练和评测又需要大量环境、光照、物体姿态和相机配置的变化。近期综述也显示,3DGS 已经渗入机器人建图、导航、操作和具身感知的多个环节 [30]。

视觉场景表示为机器人提供了接近真实环境的外观底座,但机器人操作所依赖的状态量并不完全由光度目标约束。高斯密度可以产生准确图像,却未必给出闭合表面、稳定碰撞代理或可靠接触法向。SuGaR 和 2DGS 等工作尝试改善高斯表示的表面一致性与几何质量 [4, 7],说明从可渲染外观到可交互几何仍存在关键中间层。候选动作任务后果验证正处在这一中间层之后:它接受 3DGS 带来的视觉和空间线索,同时需要判断这些线索是否足以支持某个接触动作的任务级后果。

2.2. 交互式数字孪生

当 3DGS 被放入机器人数据闭环中,它开始承担超出场景重建的系统角色。RoboSplat 利用高斯对象和单条专家演示生成视觉真实的操作数据 [27]; SplatSim 将真实场景的高斯表示用于 RGB 操作策略的零样本仿到真迁移 [22]; RoboGSim 与 Re³Sim 进一步将 3DGS 用作真到仿再到真的高保真操作数据生成载体 [11, 5]。这些工作共同推动了一个重要转变:真实世界既是最终测试环境,也可以通过可渲染数字孪生进入训练、增强和评测流程。

交互式数字孪生的另一侧是物理仿真接口。SAPIEN 和 ManiSkill 为关节物体交互和大规模操作技能评测提供了可访问的物理环境 [23, 20], PhysX 等物理引擎提供接触、约束和刚体动力学支持 [21]。GSWorld 将 3DGS 渲染接入闭环操作仿真器,使物理状态与照片级观察可以在同一系统中演化 [8]。这一方向已经具备生成候选演示和执行物理展开的关键组件;仍需要被显式定义的是二者之间的决策接口,即一个生成或规划出的候选动作在执行前应获得怎样的任务后果置信度。

2.3. 动作条件预测

世界模型把机器人决策从当前观察延伸到未来。ManiGaussian 使用动态 Gaussian Splatting 建模多任务操作中的未来场景 [14], GWM 将高斯表示扩展为可规模化的操作世界模型 [13], DreMa 则通过组合式想象支持模仿学习 [2]。更广义的动作条件预测系统,如 RoboDreamer、Video Prediction Policy

和 ChronoDreamer, 也表明未来视觉预测可以为规划、控制和策略学习提供有用中间变量 [28, 6, 29]。

这些模型的重要贡献在于让机器人能够在执行前展开想象式预测。对于视觉主导的系统, 未来帧是否自然、轨迹是否连续、物体是否沿着合理方向移动, 往往构成模型质量的重要证据。操作任务的最终判断还需要落到任务谓词: 物体是否被稳定抓住, 位移是否达到目标区域, 门或抽屉是否处于期望状态, 接触过程中是否出现导致失败的滑移或碰撞。动作条件预测因此提供了候选后果的可视化假设, 而任务后果验证需要将这些假设转化为可排序、可过滤的执行置信度。

2.4. 物理化高斯表示

为了缩小视觉场景与物理交互之间的距离, 近期工作开始为高斯表示加入动力学、材料和几何结构。PhysGaussian 将物理动力学整合进 3D 高斯图元, 用于生成式动态场景建模 [24]; Physics3D 和 GaussianProperty 分别从视频扩散或多模态大模型线索估计高斯场景中的物理属性 [12, 26]; Physically Embodied Gaussian Splatting 与 Splatting Physical Scenes 则探索可修正世界模型、显式几何和真实机器人数据之间的混合真到仿路径 [1, 19]。

物理化高斯表示的趋势表明, 3DGS 具身智能正在从外观中心表示走向交互感知表示。对机器人操作而言, 物理属性本身仍只是任务后果的一部分。相同的摩擦、质量或碰撞几何, 在不同夹爪宽度、接近方向、控制器增益和任务谓词下会产生不同执行结果; 物理属性估计的不确定性也会随接触序列被放大。候选动作验证因此需要把物理信念、可见几何、动作参数和目标谓词联合起来, 将属性恢复置于动作条件的后果推断之中。

2.5. 动作成功预测

机器人学习中已有大量工作直接面向动作可行性和成功概率。Dex-Net/GQ-CNN 将深度观测、合成抓取指标和鲁棒抓取规划结合, 用于预测抓取成功率 [15]; QT-Opt 将视觉抓取写成可扩展的闭环动作价值学习问题 [9]。在更丰富的交互任务中,

Where2Act 学习关节物体的可操作区域与动作方向 [17], Deep Affordance Foresight 预测长时序任务中的未来可供性 [25], 任务成功分类器则从少量真实演示中学习任务完成判断 [18]。Visual Foresight 进一步展示了动作条件预测与基于模型的视觉控制之间的联系 [3]。

这些研究为“动作是否值得执行”提供了成熟的机器人学习语境。3DGS 机器人数字孪生将这一问题带入新的表示条件: 输入场景来自照片级重建, 外观误差可能很小, 而接触几何、闭合表面、碰撞代理和隐藏物理属性仍带有不确定性; 候选动作也可能由演示生成、高斯世界模型、规划器或视觉语言模型提出。本文关注的候选动作任务后果验证可以看作动作成功预测在 3DGS 数字孪生中的具体化, 其核心是让任务谓词、动作参数和 3DGS 派生的几何/物理不确定性共同决定执行置信度。

3. 问题定义

本文考虑 3DGS 机器人数字孪生中的候选动作任务后果验证。令 S 表示一个 3DGS 场景, 或由 3DGS 派生的观测、几何、可见性与不确定性表示。 S 可以包含高斯图元、渲染图像、多视角观测、深度或点云估计、语义/实例线索以及几何置信度。令 g 表示任务目标, 例如抓取指定物体、将物体推动到目标区域、将物体放入容器或达到某种最终状态关系。候选动作集合为

$$\mathcal{A} = \{a_1, a_2, \dots, a_N\},$$

其中每个 a_i 是抓取、推动、放置、开合或其他操作动作的参数化表示。

任务后果验证器记为 V 。它接收场景、任务目标和候选动作, 并输出后果分数:

$$V(S, g, a_i) \rightarrow r_i,$$

其中 r_i 可表示动作 a_i 导致预期任务后果的概率、排序分数、过滤决策或置信度。动作选择可写为

$$a^* = \arg \max_{a_i \in \mathcal{A}} V(S, g, a_i),$$

过滤形式可写为

$$\mathcal{A}_{\text{valid}} = \{a_i \in \mathcal{A} \mid V(S, g, a_i) > \tau\}.$$

这里的 V 表示待研究的任务后果感知验证器，其具体实现由后续方法定义。

真实物理后果依赖 3DGS 中不可直接观测或具有不确定性的物理与几何因素。令 ξ 表示隐藏物理属性和执行扰动，包括摩擦、质量、质心、接触几何、碰撞代理误差、控制误差和接触响应。动作执行后的终态可表示为

$$s_T = \mathcal{T}(S, a_i, \xi),$$

其中 $\mathcal{T}$ 表示真实或仿真中的状态转移过程。任务目标 g 定义成功谓词 ϕ_g ，真实任务后果标签为

$$y_i = \mathbb{I}[\phi_g(s_T) = 1].$$

验证器的目标是在 ξ 和 $\mathcal{T}$ 未完全观测的情况下估计 y_i ，或使满足任务谓词的候选动作在排序中高于失败动作。

该定义区别于视觉评分和运动学验证。视觉评分关注渲染或预测观察是否逼真；运动学评分关注轨迹是否在假设几何模型下可行；任务后果验证关注接触交互之后的终态是否满足任务谓词。一个候选动作可以具有较高视觉合理性和运动学合理性，同时在隐藏物理属性或接触条件变化下缺乏任务后果一致性。

4. 诊断实验：视觉和运动学成功不能认证物理后果

本节通过 RoboSplat 式演示的物理重放诊断，刻画视觉/运动学标签与物理任务后果之间的差异。诊断结果用于为任务后果感知验证器提供经验依据。

4.1. 作为运动学演示生成器的 RoboSplat

RoboSplat 为考察视觉演示生成与物理执行之间的关系提供了合适案例。它从 3D 高斯对象生成视觉真实且空间一致的机器人演示 [27]。在原始生成流程中，物体以高斯图元表示，碰撞几何和接触动力学不属于生成物体表示的一部分。在抓取后的阶段，物体高斯图元按构造跟随末端执行器运动，从而得到与生成视觉轨迹绑定的运动学标签。这一特性使 RoboSplat 适合作为诊断设置，用于研究生成时视觉/运动学标签与物理动作后果之间的关系。





图 1. 物体位姿不确定性下的物理重放。当物理物体位于生成演示假设的位姿时，重放成功；在小幅物体位姿误差下，物理成功率快速下降，而运动学标签保持 1.0。该现象显示，生成时运动学标签并不能为测试时状态不确定性提供鲁棒执行证书。

4.2. 位姿不确定性下的物理重放

我们在 SAPIEN-PhysX 场景中使用物理代理物体重放 RoboSplat 演示，并保持相同的 Panda 机器人、控制器和时间步长。零偏移重放用于完整性检查：当物理物体位于生成演示假设的位姿时，100 次标称重放全部成功，平均最大抬升高度为 0.150 m。在物体位姿扰动下，物理成功率显著下降。507 次扰动重放的物理成功率为 0.053，而所有样本的生成时运动学标签均保持 1.0。失败主要由弱抓取导致，说明该现象来自结构化接触机制，而不是随机控制噪声。

表 1 给出该诊断的核心统计。接触率在扰动实验中仍为 1.00，失败主要来自接触质量和抓取稳定

重放设置	次数	运动学标签	物理成功率
标称位姿	100	1.0	1.000
位姿扰动	507	1.0	0.053

表 1. 位姿不确定性下的 RoboSplat 物理重放。运动学标签在标称位姿和位姿扰动重放中均为 1.0；物理成功率随位姿不确定性显著下降。




图 2. 相同视觉，不同物理后果。RoboSplat 式视觉/运动学标签在所有隐藏物理变体中保持 1.0；物理成功率随隐藏物理属性变化而分化。

性。随着物体位姿误差增大，物理成功率从亚厘米范围内的 0.73 下降到 4 cm 以上的接近 0。该趋势将运动学标签与物理任务后果之间的差异转化为可测量的验证问题。

4.3. 相同视觉，不同物理

“相同视觉、不同物理”诊断将位姿误差从分析中移除。实验固定渲染的 3DGS 观测、物体位姿、相机、机器人轨迹和运动学标签，仅在重放仿真器中改变隐藏物理属性。变化的属性包括摩擦、质量、质心偏移和隐藏碰撞宽度。所有组保持相同视觉/运动学标签，但在更现实的抓取力条件下产生不同物理执行结果。

表 2 汇总 5 N 更现实抓取力设置下的结果。标称配置的物理成功率为 1.00，说明重放环境、控制器和代理物体能够支持成功执行。改变隐藏物理属性后，摩擦扫描的成功率为 0.43，质量扫描为 0.70，质心偏移为 0.64，隐藏碰撞宽度为 0.60。主要失败模式包括滑移、弱抓取和不稳定抬升，均对应明确

隐藏属性	标签	物理成功率	主要失败
标称设置	1.0	1.00	—
摩擦	1.0	0.43	滑移 / 不稳定抬升
质量	1.0	0.70	弱抓取
质心	1.0	0.64	不稳定抬升
碰撞宽度	1.0	0.60	不稳定抬升

表 2. 相同视觉观测，不同物理后果。所有组共享相同渲染观测、物体位姿、机器人轨迹和运动学标签；仅隐藏物理属性在物理重放中变化。

的接触动力学机制。100 N 理想化强夹持会掩盖部分摩擦、质量和碰撞宽度差异，而质心偏移在强夹持下仍会造成显著失败，体现出物理理想化本身对验证结论的影响。

位姿不确定性和隐藏物理属性诊断共同揭示了视觉/运动学标签与物理任务后果之间的直接差异。观察到的失败遵循结构化物理机制，并且标称重放保持稳定。这一现象要求任务后果感知验证器同时推理可见场景证据、候选动作参数、任务谓词和隐藏物理属性的不确定性。

5. 方法

本节提出物理感知动作后果一致性验证器 (Physics-Aware Action-Effect Consistency Verifier, PAEC)，用于在 3DGS 机器人数字孪生中对候选动作进行任务后果验证。PAEC 接收场景表示 S 、任务目标 g 和候选动作 a_i ，输出物理后果一致性分数、失败类型估计，并在低置信度时给出动作修正建议。方法的核心是显式区分可见状态与隐藏物理属性：可见状态由 3DGS/RGB 观测、物体位姿和机器人状态提供；摩擦、质量、质心和接触几何等属性被表示为物理信念，而非由视觉直接确定。

5.1. 概览

PAEC 位于生成或规划模块之后、真实执行之前。候选动作可以来自 RoboSplat 式演示生成、高斯世界模型、运动规划器、视觉语言模型规划器或视觉运动策略。与只评估渲染质量或轨迹可达性的模块不同，PAEC 估计该动作在隐藏物理不确定性

PAEC 流程占位图

3DGS/RGB 观测 + 候选动作 → 可见代理构建 → 物理信念初始化 → 物理条件融合 → 成功 / 失败 / 指标 / 修正预测头

图 3. PAEC 概览占位图。给定 3DGS/RGB 观测和候选动作，PAEC 首先构建可见物体代理，并初始化隐藏物理属性的信念分布。候选动作、机器人状态和物理信念分别编码后，在物理条件融合模块中融合，用于预测任务成功概率、失败类型、物理指标和动作修正量。可选的安全物理探测可在执行前更新物理信念。

下是否能够实现任务谓词 ϕ_g 。

给定候选动作 a_i ，PAEC 首先从 S 中提取可见代理 x_v ，并为隐藏物理变量建立信念分布 $b(\theta)$ 。随后，动作编码器、机器人状态编码器和物理信念编码器分别产生特征表示，并通过物理条件融合得到联合表示 z_i 。验证器输出

$$(r_i, p_i^{\text{fail}}, m_i, \Delta a_i) = \text{PAEC}(S, g, a_i, b(\theta)),$$

其中 r_i 是动作满足任务谓词的估计概率， p_i^{fail} 是失败类型分布， m_i 是抬升高度、滑移距离、倾斜角等任务相关物理指标， Δa_i 是可选的动作修正残差。

5.2. 可见代理构建

3DGS 提供照片级渲染和空间一致性，但其高斯图元并不天然等价于可接触物理对象。因此，PAEC 首先构建一个面向验证的可见代理：

$$x_v = h_{\text{proxy}}(S, g).$$

该代理包括物体位姿、尺度、可见几何范围、近似接触区域、候选抓取区域、相机可见性和任务相关空间关系。对于抓取任务， x_v 可包含物体边界框、候选接触面的相对位置、物体长宽高、目标抬升方向与夹爪开合方向之间的关系。对于推动或放置任务， x_v 可进一步包含支撑面、目标区域和障碍物关系。

可见代理的作用是提供可由视觉观测支持的状态信息。它不承担恢复真实摩擦、质量或质心的任务。该设计使方法避免将视觉上不可辨识的物理属性错误地编码为确定观测量。实现上， x_v 可以由结

构化几何描述符、高斯对象特征、RGB/深度特征或它们的组合编码，得到视觉/几何嵌入 e_{vis} ：

$$e_{\text{vis}} = E_{\text{vis}}(x_v).$$

5.3. 物理信念初始化

隐藏物理属性记为

$$\theta = \{\mu, m, c, \kappa, F\},$$

其中 μ 表示摩擦， m 表示质量， c 表示质心偏移， κ 表示接触或碰撞几何， F 表示夹持力或控制力条件。“相同视觉、不同物理”诊断表明，相同视觉观测可以对应不同 θ ，并产生不同任务后果。因此，PAEC 使用信念分布表示这些隐藏属性：

$$b_0(\theta) = p(\theta | x_v, \pi_{\text{cat}}, \pi_{\text{mat}}, \pi_{\text{task}}),$$

其中 π_{cat} 、 π_{mat} 和 π_{task} 分别表示类别、材质和任务先验。

在最小实现中， $b_0(\theta)$ 可由手工设定的物理范围给出，例如摩擦范围、质量范围、质心偏移上界和若干候选碰撞几何。更完整的实现可以由物体类别、材质提示或历史交互统计初始化。关键在于，PAEC 不需要在操作前确定真实 θ ，而是评估动作在 $b(\theta)$ 所覆盖的可能物理条件下是否鲁棒。

为了将信念输入网络，我们从 $b(\theta)$ 中采样 K 个物理假设：

$$\theta_k \sim b(\theta), \quad k = 1, \dots, K.$$

每个样本由物理编码器编码为

$$e_{\theta,k} = E_{\theta}(\theta_k),$$

随后通过均值池化、注意力池化或 Set Transformer 聚合为信念嵌入：

$$e_{\text{phys}} = \text{Pool}(\{e_{\theta,k}\}_{k=1}^K).$$

该嵌入描述的不是单一物理状态，而是当前动作面对的物理不确定性。

5.4. 候选动作编码

候选动作 a_i 可表示为低层控制序列，也可表示为高层动作参数。对于抓取任务，我们使用以下信息构造动作特征：末端执行器轨迹、夹爪宽度、抓取位姿、接近方向、抬升方向、抬升速度和抓取力。动作序列编码为

$$e_{\text{act}} = E_{\text{act}}(a_i),$$

其中 E_{act} 可以是时间卷积、GRU 或 Transformer 编码器。机器人初始状态和执行上下文由

$$e_{\text{robot}} = E_{\text{robot}}(q_0, x_{\text{ee}}, w_{\text{gripper}})$$

编码，其中 q_0 是初始关节状态， x_{ee} 是末端执行器位姿， w_{gripper} 是夹爪状态。

这种动作表示保留了后续修正所需的参数结构。若只将动作视为黑盒轨迹，验证器可以给出失败概率，却难以解释应当如何修正。将动作拆解为抓取位姿、力、宽度和抬升速度等参数后，失败类型能够自然连接到动作调整。

5.5. 物理感知验证

PAEC 的关键模块是物理条件融合。由于同一动作在不同物理属性下可能产生不同后果，物理信念应直接调制动作表示。我们使用 FiLM 式调制作为一种实现：

$$\gamma, \beta = M_{\text{film}}(e_{\text{phys}}),$$

$$\tilde{e}_{\text{act}} = \gamma \odot e_{\text{act}} + \beta.$$

随后融合可见代理、物理调制后的动作特征、机器人状态和物理信念：

$$z_i = M_{\text{fuse}}([e_{\text{vis}}, \tilde{e}_{\text{act}}, e_{\text{robot}}, e_{\text{phys}}]).$$

该融合也可由交叉注意力实现，使动作阶段 token 与摩擦、质量、质心和接触几何 token 交互。FiLM 版本更适合作为简洁实现，因为它明确表达了“物理条件改变同一动作的可执行性”。

验证器从 z_i 预测动作后果：

$$r_i = \sigma(h_{\text{succ}}(z_i)),$$

$$p_i^{\text{fail}} = \text{softmax}(h_{\text{fail}}(z_i)),$$

$$m_i = h_{\text{metric}}(z_i).$$

其中 r_i 是任务成功概率， p_i^{fail} 包括弱抓取、滑移、不稳定抬升、倾斜/掉落和碰撞不匹配等失败类型， m_i 回归最大抬升高度、滑移距离、倾斜角、接触持续时间等物理指标。

若采用显式采样评估，也可以对每个物理假设单独预测：

$$r_i = \frac{1}{K} \sum_{k=1}^K p_{\psi}(y=1 | x_v, g, a_i, \theta_k),$$

并记录最差情形分数：

$$r_i^{\text{worst}} = \min_k p_{\psi}(y=1 | x_v, g, a_i, \theta_k).$$

前者衡量平均鲁棒性，后者适合高风险任务中的保守动作筛选。

5.6. 验证器引导的过滤与修正

PAEC 的输出用于候选动作过滤和修正。过滤形式与问题定义中的形式一致：

$$\mathcal{A}_{\text{valid}} = \{a_i \in \mathcal{A} | r_i > \tau\}.$$

当 r_i 低于阈值时，动作仍可能在视觉和运动学空间中合理，但其物理鲁棒性不足。此时系统可以丢弃该候选，或根据失败类型进行参数修正。

修正头输出动作残差：

$$\Delta a_i = h_{\text{corr}}(z_i), \quad a'_i = a_i + \Delta a_i.$$

在抓取任务中, Δa_i 可包含夹持力调整、夹爪宽度调整、抓取点偏移、抬升速度调整和抬升方向调整。不同失败类型对应不同修正方向: 滑移风险通常对应更高夹持力或更低抬升速度; 弱抓取对应夹爪宽度、接触点和力裕度调整; 不稳定抬升或倾斜对应抓取点和抬升方向调整。

在未训练修正头的实现中, 也可以使用验证器引导搜索:

$$a'_i = \arg \max_{\hat{a} \in \mathcal{N}(a_i)} V(S, g, \hat{a}),$$

其中 $\mathcal{N}(a_i)$ 是围绕原动作的局部参数邻域, 例如不同抓取力、夹爪宽度、抬升速度和抓取偏移的组合。该基于搜索的修正与学习式修正共用同一验证器接口。

5.7. 可选安全物理探测

对于未见过物体, 视觉和先验可能无法充分约束 $b(\theta)$ 。PAEC 可在完整执行前引入低风险物理探测, 例如轻微夹持、微抬升、轻推或小幅扰动。探测产生观测 z_{probe} , 包括相对滑移、倾斜角、夹爪闭合量、接触持续时间和微抬高度变化。信念由

$$b_1(\theta) = p(\theta | x_v, z_{\text{probe}})$$

更新, 并用于后续验证和修正。

该模块将未知物体的物理问题转化为测试时不确定性更新, 而不是要求视觉模型在交互前精确恢复摩擦、质量或质心。若不允许探测, PAEC 仍可使用仅先验信念进行保守验证; 若任务风险较高或信念不确定性较大, 则先探测后验证的策略更适合减少完整执行失败。

5.8. 训练信号

PAEC 的监督信号来自物理展开, 而非生成时的视觉或运动学标签。每个训练样本包含可见代理、候选动作、机器人状态、物理假设 θ 和展开后果标签。后果标签包括任务成功、失败类型和连续物理指标。训练目标为

$$\mathcal{L} = \mathcal{L}_{\text{succ}} + \lambda_f \mathcal{L}_{\text{fail}} + \lambda_m \mathcal{L}_{\text{metric}} + \lambda_c \mathcal{L}_{\text{corr}},$$

其中 $\mathcal{L}_{\text{succ}}$ 是二分类成功损失, $\mathcal{L}_{\text{fail}}$ 是失败类型交叉熵, $\mathcal{L}_{\text{metric}}$ 回归抬升、滑移和倾斜等物理指标, $\mathcal{L}_{\text{corr}}$ 在存在搜索得到的修正动作时监督修正头。

这一训练设计使网络学习物理动作后果, 而不是复现视觉标签。对于“相同视觉、不同物理”中视觉完全一致的样本, 仅 RGB 或仅运动学输入无法区分不同物理后果; PAEC 通过显式物理信念和物理展开后果监督学习同一动作在不同物理条件下的后果差异。

6. 实验

7. 结果

8. 讨论

9. 结论

参考文献

- [1] J. Abou-Chakra, K. Rana, F. Dayoub, and N. Sünderhauf. Physically embodied gaussian splatting: A realtime correctable world model for robotics. arXiv preprint arXiv:2406.10788, 2024. 3
- [2] L. Barcellona, A. Zadaianchuk, D. Allegro, S. Papa, S. Ghidoni, and E. Gavves. Dream to manipulate: Compositional world models empowering robot imitation learning with imagination. arXiv preprint arXiv:2412.14957, 2024. 1, 2
- [3] F. Ebert, C. Finn, S. Dasari, A. Xie, A. Lee, and S. Levine. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. arXiv preprint arXiv:1812.00568, 2018. 3
- [4] A. Guédon and V. Lepetit. SuGaR: Surface-aligned gaussian splatting for efficient 3D mesh reconstruction and high-quality mesh rendering. In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024. 2
- [5] X. Han, M. Liu, Y. Chen, J. Yu, X. Lyu, Y. Tian, B. Wang, W. Zhang, and J. Pang. Re³Sim: Generating high-fidelity simulation data via 3D-photorealistic real-to-sim for robotic manipulation. arXiv preprint arXiv:2502.08645, 2025. 1, 2
- [6] Y. Hu, Y. Guo, P. Wang, X. Chen, Y.-J. Wang, J. Zhang, K. Sreenath, C. Lu, and J. Chen. Video

- prediction policy: A generalist robot policy with predictive visual representations. arXiv preprint arXiv:2412.14803, 2024. 3
- [7] B. Huang, Z. Yu, A. Chen, A. Geiger, and S. Gao. 2D gaussian splatting for geometrically accurate radiance fields. In ACM SIGGRAPH Conference Papers, 2024. 2
- [8] G. Jiang, H. Chang, R.-Z. Qiu, Y. Liang, M. Ji, J. Zhu, Z. Dong, X. Zou, and X. Wang. GSWorld: Closed-loop photo-realistic simulation suite for robotic manipulation. arXiv preprint arXiv:2510.20813, 2025. 1, 2
- [9] D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, E. Jang, D. Quillen, E. Holly, M. Kalakrishnan, V. Vanhoucke, and S. Levine. QT-Opt: Scalable deep reinforcement learning for vision-based robotic manipulation. arXiv preprint arXiv:1806.10293, 2018. 3
- [10] B. Kerbl, G. Kopanas, T. Leimkühler, and G. Dretakis. 3D Gaussian splatting for real-time radiance field rendering. ACM Transactions on Graphics, 42(4), 2023. 1, 2
- [11] X. Li, J. Li, Z. Zhang, R. Zhang, F. Jia, T. Wang, H. Fan, K.-K. Tseng, and R. Wang. RoboGSim: A real2sim2real robotic gaussian splatting simulator. arXiv preprint arXiv:2411.11839, 2024. 1, 2
- [12] F. Liu, H. Wang, S. Yao, S. Zhang, J. Zhou, and Y. Duan. Physics3D: Learning physical properties of 3D gaussians via video diffusion. arXiv preprint arXiv:2406.04338, 2024. 3
- [13] G. Lu, B. Jia, P. Li, Y. Chen, Z. Wang, Y. Tang, and S. Huang. GWM: Towards scalable gaussian world models for robotic manipulation. In IEEE/CVF International Conference on Computer Vision (ICCV), 2025. 1, 2
- [14] G. Lu, S. Zhang, Z. Wang, C. Liu, J. Lu, and Y. Tang. ManiGaussian: Dynamic gaussian splatting for multi-task robotic manipulation. arXiv preprint arXiv:2403.08321, 2024. 1, 2
- [15] J. Mahler, J. Liang, S. Niyaz, M. Laskey, R. Doan, X. Liu, J. A. Ojea, and K. Goldberg. Dex-Net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics. In Robotics: Science and Systems (RSS), 2017. 3
- [16] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng. NeRF: Representing scenes as neural radiance fields for view synthesis. In European Conference on Computer Vision (ECCV), 2020. 2
- [17] K. Mo, L. Guibas, M. Mukadam, A. Gupta, and S. Tulsiani. Where2Act: From pixels to actions for articulated 3D objects. In IEEE/CVF International Conference on Computer Vision (ICCV), 2021. 3
- [18] A. Mohtasib, A. Ghalamzan E., N. Bellotto, and H. Cuayáhuitl. Neural task success classifiers for robotic manipulation from few real demonstrations. arXiv preprint arXiv:2107.00722, 2021. 3
- [19] B. Moran, M. Comi, A. Byravan, S. Bohez, T. Erez, Z. Li, and L. Hasenclever. Splatting physical scenes: End-to-end real-to-sim from imperfect robot data. arXiv preprint arXiv:2506.04120, 2025. 3
- [20] T. Mu, Z. Ling, F. Xiang, D. Yang, X. Li, S. Tao, Z. Huang, Z. Xu, and H. Su. ManiSkill: Generalizable manipulation skill benchmark with large-scale demonstrations. In Advances in Neural Information Processing Systems Datasets and Benchmarks Track, 2021. 1, 2
- [21] NVIDIA. NVIDIA PhysX SDK. <https://github.com/NVIDIA-Omniverse/PhysX>, 2025. Accessed 2026-06-16. 1, 2
- [22] M. N. Qureshi, S. Garg, F. Yandun, D. Held, G. Kantor, and A. Silwal. SplatSim: Zero-shot sim2real transfer of RGB manipulation policies using gaussian splatting. arXiv preprint arXiv:2409.10161, 2024. 1, 2
- [23] F. Xiang, Y. Qin, K. Mo, Y. Xia, H. Zhu, F. Liu, M. Liu, H. Jiang, Y. Yuan, H. Wang, L. Yi, A. X. Chang, L. J. Guibas, and H. Su. SAPIEN: A simulated part-based interactive environment. In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020. 1, 2
- [24] T. Xie, Z. Zong, Y. Qiu, X. Li, Y. Feng, Y. Yang, and C. Jiang. PhysGaussian: Physics-integrated 3D gaussians for generative dynamics. In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024. 3
- [25] D. Xu, A. Mandlekar, R. Martín-Martín, Y. Zhu, S. Savarese, and L. Fei-Fei. Deep affordance foresight: Planning through what can be done in the future. arXiv preprint arXiv:2011.08424, 2020. 3
- [26] X. Xu, W. Ge, D. Qiu, Z. Chen, D. Yan, Z. Liu, H. Zhao, H. Zhao, S. Zhang, J. Liang, and Y.-C. Chen. GaussianProperty: Integrating physical prop-

972	erties to 3D gaussians with LMMs. arXiv preprint	1026
973	arXiv:2412.11258, 2024. 3	1027
974		1028
975	[27] S. Yang, W. Yu, J. Zeng, J. Lv, K. Ren, C. Lu, D. Lin,	1029
976	and J. Pang. Novel demonstration generation with	1030
977	gaussian splatting enables robust one-shot manipula-	1031
978	tion. arXiv preprint arXiv:2504.13175, 2025. 1, 2, 4	1032
979		1033
980	[28] S. Zhou, Y. Du, J. Chen, Y. Li, D.-Y. Yeung,	1034
981	and C. Gan. RoboDreamer: Learning compositional	1035
982	world models for robot imagination. arXiv preprint	1036
983	arXiv:2404.12377, 2024. 3	1037
984		1038
985	[29] Z. Zhou and D. Negrut. ChronoDreamer: Action-	1039
986	conditioned world model as an online simulator for	1040
987	robotic planning. arXiv preprint arXiv:2512.18619,	1041
988	2025. 3	1042
989		1043
990	[30] S. Zhu, G. Wang, X. Kong, D. Kong, and H. Wang.	1044
991	3D gaussian splatting in robotics: A survey. arXiv	1045
992	preprint arXiv:2410.12262, 2024. 2	1046
993		1047
994		1048
995		1049
996		1050
997		1051
998		1052
999		1053
1000		1054
1001		1055
1002		1056
1003		1057
1004		1058
1005		1059
1006		1060
1007		1061
1008		1062
1009		1063
1010		1064
1011		1065
1012		1066
1013		1067
1014		1068
1015		1069
1016		1070
1017		1071
1018		1072
1019		1073
1020		1074
1021		1075
1022		1076
1023		1077
1024		1078
1025		1079